台股多因子機器學習選股｜研究成果

數據分析與機器學習職前訓練專題 · 適合職缺為金融量化分析師 / 機器學習工程師

首頁為摘要內容單元；Markdown 本身不保證實體頁數，轉 PDF 時依分頁標記排版。

第一頁｜摘要與結論

核心成果：完成可追溯的台股選股研究流程。最終 XGBoost Pseudo-Huber 在六年串接 OOS 呈現正報酬與較淺回撤，但報酬落後同期大盤；較適合定位為控制風險的主動選股研究。

最終版本：oos-2020-2025-factor-v4-pseudohuber-NOrefit（六個年度 run 的統稱）。四年訓練 → 一年驗證 → 次年 OOS；各年度重新訓練及調參，驗證後不合併資料 refit。月末選 Top15，既有持股排名仍在 Top30 可續抱；反波動權重，α=1、不平滑。

FinMind / 官方資料等 → SQLite 時點資料 → 股票池 + 27 因子月截面
→ Purge / Optuna / 凍結年度模型 → 次年 OOS 排名
→ Top15 / Hold30 + 反波動配置 + 大盤 MA60 風控
→ 次日開盤模擬成交 / 扣成本 → 績效、SHAP、消融、Bootstrap、儀表板

六年串接指標	策略	同期 TAIEX
年化報酬 CAGR	13.24%	19.31%
Sharpe	1.031	0.998
Sortino	1.359	1.275
MDD	-19.59%	-31.63%
累積報酬	105.97%	178.93%

評估範圍：2020-2025 為訊號年度，實際估值日期 2020-02-03 ~ 2026-01-30，共 1,464 個交易日；含各年度首日相對初始資金的報酬，TAIEX 使用相同日期的收盤對收盤報酬（首日基準為 2020-01-31 收盤）。此為年度獨立回測的報酬串接，尚非跨年承接原持股的單一帳戶重跑。大盤為價格指數，非含息指數。

SHAP Top3：beta_60d（8.8%）；**close_60d_high**（8.0%）；**sales_yield**（7.0%）。此為六個年度「最後一期截面」的 mean(|SHAP|) 各自正規化後等權平均占比，**不是全年 SHAP，也不是報酬貢獻或因果證據**。

優點：時點資料與 purge 降低前視風險；將交易成本及曝險控制納入評估；六個年度的平均 Rank IC、Top15 超額與 Top-Bottom spread 均為正；研究輸出可追溯到 run、模型與資料表。

缺點：強勢市場追不上大盤；換手偏高（六年度平均約 9.91 倍）

第二頁｜研究設計與績效口徑

問題與驗證方式

研究問題是「能否利用當時已知的基本面、價量、風險與籌碼因子，排序下期較有潛力的股票，並轉成扣成本的可執行投組？」選股能力和投組績效分開檢驗。

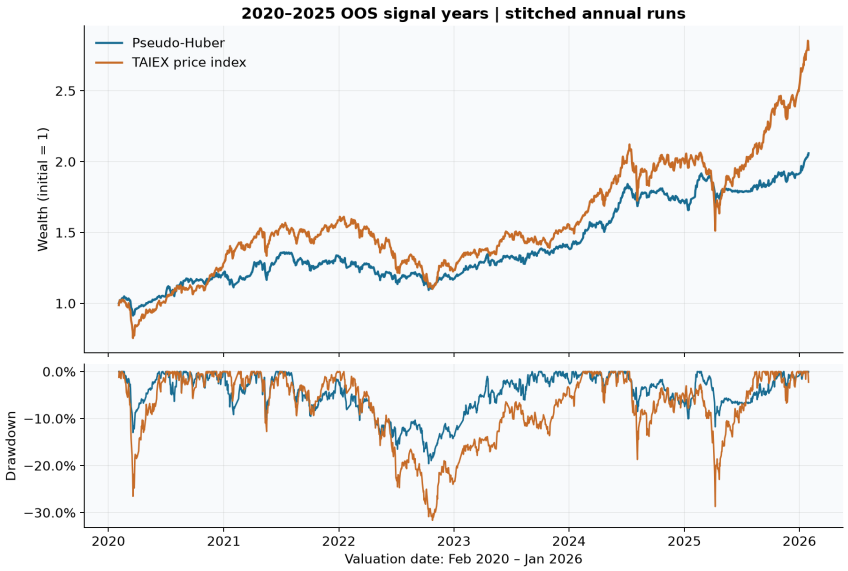
項目	設計
股票池	市值至少 50 億、20 日均成交值至少 2,000 萬、股價至少 10 元、上市滿 252 交易日；v4 要求關鍵財務與調整價資料
資料處理	財報依可得時點、還原價用於因子與標籤；截面缺值填補與極端值處理；排除規則及門檻見 config.factor_v4.yaml
年度切分	OOS 年 Y：Y-5 至 Y-2 的訓練區間（末月 purge）、Y-1 驗證、Y 測試；20 交易日標籤隔離
最終模型	27 個共同特徵；XGBoost reg:pseudohubererror；每年 50 次 Optuna；NOrefit
標籤	未來 20 個個股交易日還原價報酬；回歸預測相對當期股票池均值的連續超額報酬；二元分類以截面前 20% 為正類
個股配置	Top15 / Hold30；最多單檔 10%；反波動權重
總曝險	目標年波動 15%、曝險上限 100%、TAIEX 低於 MA60 時採減碼規則
執行與成本	月底收盤訊號、次交易日開盤；手續費單邊 0.1425%、賣出稅 0.3%、滑價單邊 0.1%

必須區分的三種數字

1. **六年串接績效**：首頁由日報酬重新複利，再計算整段 CAGR、Sharpe、Sortino、MDD。年度初始資金均為 3,000 萬，串接時不把帳戶金額重設誤當損益。
2. **年度期間報酬**：每個訊號年度實際持有期間的累積報酬；不是 1 月至 12 月曆年報酬。下表另列同段 CAGR，兩者不能混稱。
3. **比較研究的年度平均**：後文多數表格是五個年度 artifact 指標的算術平均，並非五年 CAGR，平均年度 MDD 也不是整段最大回撤。

本文件首頁及下表採 CAGR=累積財富^(252/N)-1；Sharpe 為日平均 / 日報酬樣本標準差 × √252，無風險利率設為 0；Sortino 沿用專案「日平均 / 負報酬日樣本標準差 × √252」，**不是以全樣本下檔半變異數計算的版本**。MDD 含起始財富 1。大盤首日含前收至當日收盤變動；策略年度首日由開盤建倉及成本決定，兩者日內起點並非完全一致。

訊號年度	策略期間報酬	大盤期間報酬	策略 CAGR	大盤 CAGR	Sharpe 策 / 盤	Sortino 策 / 盤	MDD 策 / 盤
2020	13.11%	31.69%	13.22%	31.98%	0.98 / 1.44	1.27 / 1.87	-12.97% / -26.53%
2021	10.59%	16.75%	11.10%	17.58%	0.79 / 1.05	1.13 / 1.43	-10.35% / -12.74%
2022	-1.86%	-13.63%	-1.94%	-14.21%	-0.08 / -0.64	-0.10 / -0.98	-15.53% / -30.93%
2023	15.82%	17.19%	16.10%	17.49%	1.35 / 1.41	1.98 / 2.23	-5.86% / -7.69%
2024	22.00%	31.50%	23.76%	34.13%	1.79 / 1.48	2.46 / 1.69	-10.03% / -18.69%
2025	18.74%	36.29%	18.99%	36.80%	1.57 / 1.42	1.82 / 1.71	-11.74% / -26.71%



六年串接淨值與回撤，策略及 TAIEX

解讀：低曝險與減碼有助降低下跌損失，也限制多頭參與度。每年選股診斷為正，不等於每月為正，亦不等於投組必定超越 TAIEX。Top15 excess 的基準是當月股票池均值，不是 TAIEX。

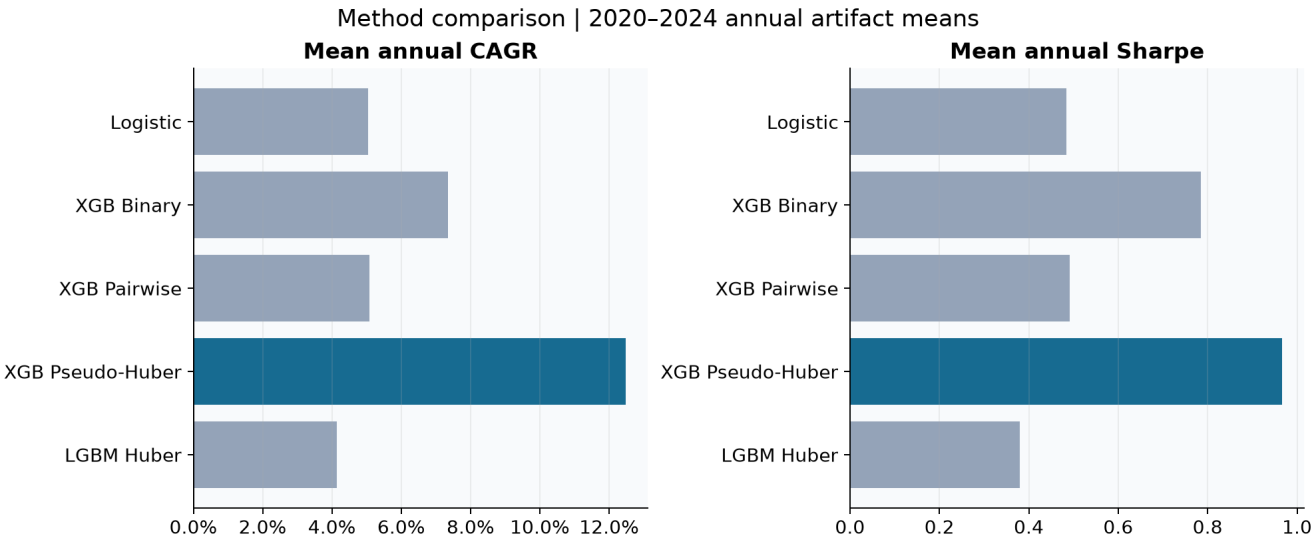
來源：database/quant.db → run_artifacts(metrics/monthly_ic)、prices(stock_id=TAIEX)；重算底稿 annual_recomputed.csv 與 stitched_daily.csv。

第三頁｜不同 method / objective 比較

共同評估期間為 **2020-2024**，因 Logistic、Pairwise、LightGBM 未具同系列完整 2025 結果。下表取整理當下資料庫的年度 artifact 平均，不將不同期間混排。

方法	平均年度 CAGR	平均 Sharpe	平均 Sortino	平均年度 MDD	年換手 x	平均 Rank IC
Logistic Regression	5.05%	0.484	0.727	-11.02%	6.21	-0.064
XGBoost Binary	7.35%	0.785	1.184	-9.11%	5.71	-0.063
XGBoost Pairwise	5.08%	0.491	0.764	-12.07%	7.69	-0.069
XGBoost Pseudo-Huber	12.48%	0.967	1.353	-10.95%	10.16	0.034
LightGBM Huber	4.14%	0.379	0.563	-13.15%	8.70	0.033

方法	學習目標與比較意義
Logistic Regression	固定線性二元分類基準；觀察非線性模型是否增加價值
XGBoost Binary	binary:logistic；預測進入前 20% 的機率
XGBoost Pairwise	rank:pairwise；學習相對排序
XGBoost Pseudo-Huber	reg:pseudohubererror；對連續超額報酬採穩健損失
LightGBM Huber	huber；另一個樹模型與穩健回歸實作



不同模型平均年度報酬及 Sharpe

結論：在這組已完成實驗中，Pseudo-Huber 的平均報酬、Sharpe 與連續 Rank IC 較佳；Binary 的全截面 IC 可為負但頭部選股仍可能有價值，因此不能只用全域 IC 決定模型。LightGBM Huber 未複製 XGBoost 的結果；此比較同時改變演算法、損失實作與搜尋空間，不能推論 XGBoost 在所有資料上優於 LightGBM，亦非單純 objective 的因果實驗。

來源：methods_annual.csv、lightgbm_huber_vs_xgboost_pseudohuber_summary_2020_2024.csv。表格只代表已完成的模型，未虛構其他 XGBoost / LightGBM objective。

第四頁｜投組緩衝與權重

不同緩衝與投組規模（2020-2024 保存實驗）

規則	平均 CAGR	平均 Sharpe	平均 Sortino	平均年度 MDD	換手 x	平均持股數
Top15/Hold15	13.62%	0.944	1.283	-11.87%	10.76	15.0
Top15/Hold30	12.71%	0.921	1.275	-11.45%	10.09	16.1
Top30/Hold60	7.43%	0.664	0.868	-11.37%	10.26	33.4

Top15 / Hold15 相當於沒有排名緩衝；Hold30 可讓跌出前 15、但仍在前 30 的舊持股續抱，所以實際檔數可能大於 15。加入 Hold30 後平均換手由 10.76 降至 10.09 倍，但 CAGR 也下降，並未同時改善所有指標。Top30 / Hold60 同時增加新買入數量與續抱範圍，不能把全部差異歸因於緩衝。

本表保留原比較 CSV 的同批基準（12.71%），不將後來重物化的 12.48% 插入舊對照。尚未重跑全部變體驗證現行資料下是否同方向。

更寬的續抱門檻：僅有 2020，不外推五年

方法	平均年度 CAGR	平均 Sharpe	平均 Sortino	平均年度 MDD	年換手 x	平均 Rank IC
Hold30	12.99%	0.970	1.252	-12.97%	10.72	0.012
Hold45	12.04%	0.945	1.179	-12.60%	10.25	0.012
Hold60	10.61%	0.866	1.083	-12.60%	10.04	0.012

此三組固定 Top15。2020 單年 Hold45 / Hold60 未勝過現有 Hold30 baseline；尚不足以宣稱寬緩衝在所有年度較差。來源：當前 run artifacts；hold_threshold_2020.csv。

反波動與等權（2020-2024）

個股權重	平均 CAGR	平均 Sharpe	平均 Sortino	最差年度 MDD	實現波動	換手 x
inverse_volatility	12.48%	0.967	1.353	-15.53%	13.11%	10.16
equal	11.43%	0.821	1.160	-16.27%	14.28%	10.05

結論：反波動個股權重的平均 CAGR 高約 1.05 個百分點，Sharpe 高約 0.146，實現波動較低；換手未改善。兩組平均總曝險相同（55.42%），所以這是**個股權重**差異，不是拿低曝險策略和滿倉等權比較。

來源：three_buffer_strategies_summary_2020_2024.csv、equal_weight_vs_inverse_volatility_summary_2020_2024.csv。原檔的年度 CAGR 複乘欄位不作為連續淨值報酬使用。

第五頁｜月中資料增廣與分數平滑

月中增廣：2024 單一 OOS 年度

「月中資幅」依專案檔案解讀為**月中資料增廣**：增加訓練截面，不是每月多換倉一次。

訓練資料	樣本數	截面數	驗證 IC	OOS IC	CAGR	Sharpe	MDD	換手 x
month_end_only	21056	47	0.082	0.083	23.82%	1.793	-10.03%	11.82
month_end_plus_midmonth	41900	94	0.067	0.051	13.10%	1.128	-7.10%	8.30

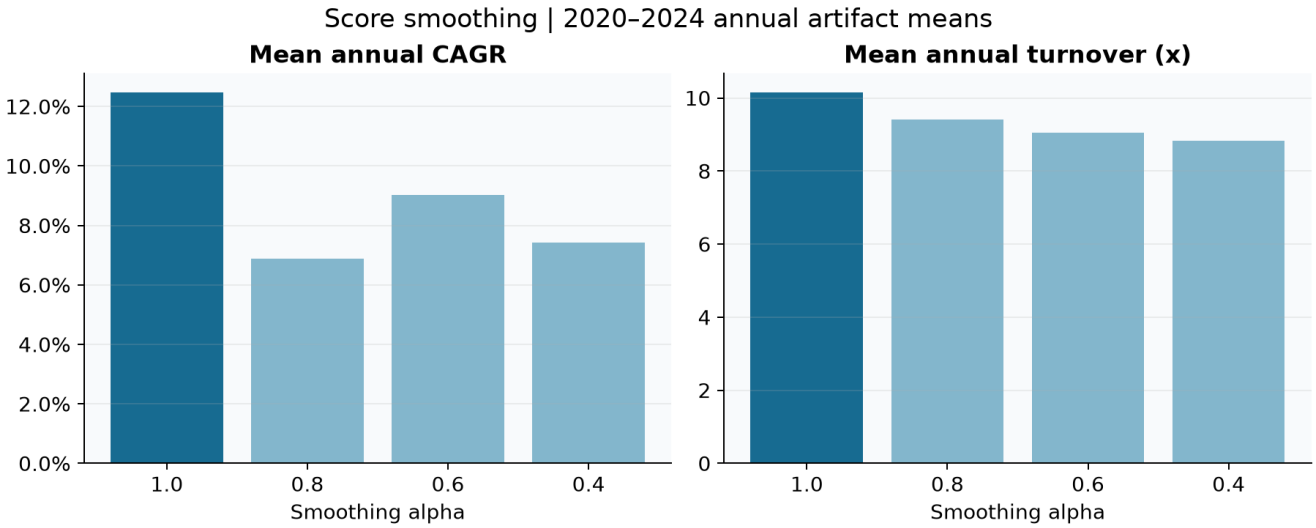
增加 20,844 筆月中資料後，驗證 IC 與 OOS IC 均下降，CAGR 減少 10.72 個百分點；MDD 改善約 2.93 個百分點，換手亦降低。**資料量變多不保證泛化改善**，可能涉及相鄰截面資訊重複與分布改變；成因尚未單獨驗證，不能作為既定因果結論。

來源：midmonth_augmented_vs_monthend_oos2024.csv。

分數平滑 α（2020-2024）

平滑分數_t = α × 當期截面百分位 + (1-α) × 上期平滑分數；α=1 代表不平滑。股票首次出現時用當期值。

方法	平均年度 CAGR	平均 Sharpe	平均 Sortino	平均年度 MDD	年換手 x	平均 Rank IC
α=1.0	12.48%	0.967	1.353	-10.95%	10.16	0.034
α=0.8	6.87%	0.565	0.746	-11.68%	9.42	0.036
α=0.6	9.02%	0.730	1.003	-12.05%	9.04	0.037
α=0.4	7.43%	0.614	0.813	-10.99%	8.83	0.036



平滑係數與平均年度報酬、換手率

結論：平滑在部分年份有效，但整體降低反應速度、拖累平均報酬與 Sharpe；換手降幅相對有限，因此最終保留 α=1。α=1 是目前 baseline，其他 α 是保存的舊實驗，仍有物化版本差異的限制，適合呈現方向性證據，不能聲稱嚴格單因子因果效果。

來源：smoothing_annual.csv；實作 tools/run_oos_portfolio.py::_smooth_percentile_scores。

第六頁｜Class weight 與特徵消融

二元分類的 class weight（2020-2025）

僅比較不加權與**固定原參數、正類權重 4:1**，依需求排除 class weight + Optuna 組。權重只作用在訓練損失，驗證 / OOS 不加權。這是 Binary 模型的實驗，不能直接當作 Pseudo-Huber 的對照。

Binary 版本	串接 CAGR	Sharpe	Sortino	串接 MDD	平均 Rank IC	Top15 excess	換手 x
unweighted	7.53%	0.701	0.942	-17.70%	-0.055	1.03%	5.78
classweight4_fixedparams	6.33%	0.588	0.787	-18.65%	-0.053	1.23%	5.86

加權後 CAGR 下降約 1.20 個百分點，Sharpe 下降 0.114，MDD 更深；但 Top15 excess 提升，顯示訓練損失、選股頭部表現與投組損益不必然同方向。以投組結果看，尚無證據支持採用固定 4:1 加權。

口徑註：此表沿用原研究的逐年 pct_change().dropna() 串接，未納入每年首日對初始資金的變動；不是首頁的含首日口徑。兩組內部可比較，但不直接用本表與首頁排名。

來源：binary_classweight4_oos2020_2025_summary.csv、tools/report_binary_classweight4_oos2020_2025.py::_stitched_metrics。

Beta 消融：SHAP 高，不等於不可替代

模型	平均 CAGR	平均 Sharpe	平均年度 MDD	平均 OOS IC	Top15 excess
baseline	13.08%	1.036	-11.08%	0.033	1.22%
fixedparams	8.80%	0.720	-12.98%	0.042	0.69%
optuna	6.86%	0.530	-12.53%	0.039	0.04%

固定參數移除 beta_60d 後，平均 IC 反而增加 0.009，但平均 Sharpe 降低 0.316、Top15 excess 減少 0.53 個百分點。72 個月配對 Bootstrap 的 IC 差異 95% 區間約 [-0.001, 0.019]，Top15 excess 差異約 [-1.42%, +0.34%]，均涵蓋 0。重新 Optuna 的 Beta 消融仍列為補充實驗；此組並非已排除的 class weight + Optuna。

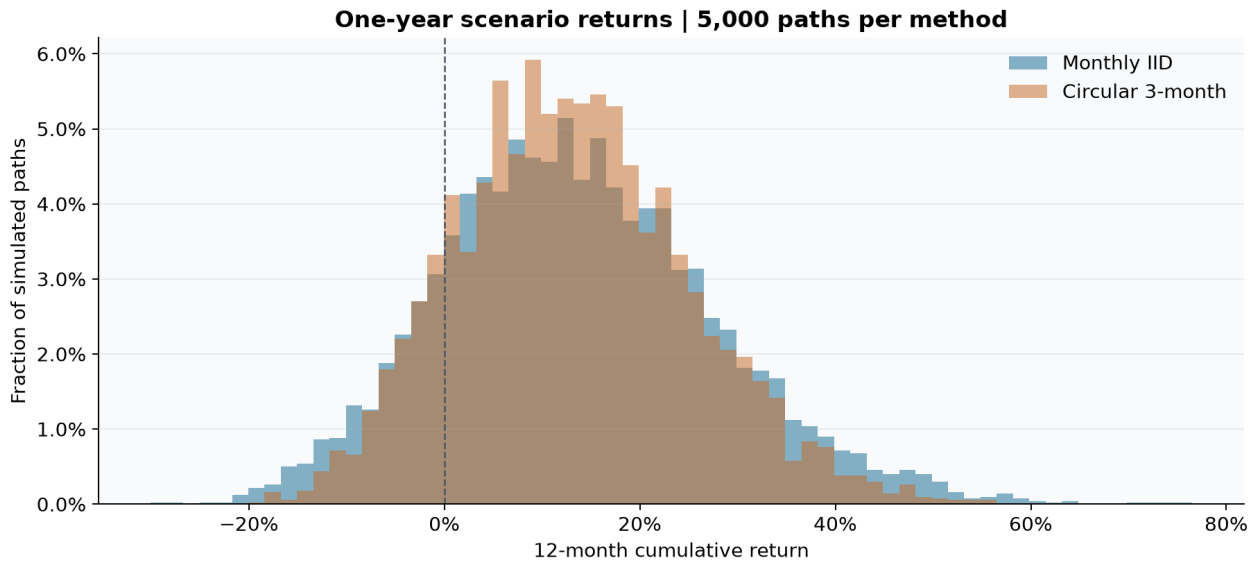
結論：暫時保留 Beta 有經濟結果支持，但不能因 SHAP 排名高就宣稱它是核心 Alpha；訊號可能與波動、動能及市場狀態共同作用。

來源：beta60_ablation_report.md、beta60_ablation_2020_2025_paired_monthly_summary.csv。

第七頁｜拔靴法：未來一年可能情境的歷史模擬

以 2020-2025 的 **72 個持有月份**為樣本，每條路徑抽取 12 個月，保留每月內的日報酬。比較單月 IID 與三個月 circular block，各 5,000 條路徑；另有 500 / 2,000 次結果供收斂檢查。

方法	一年累積報酬均值	中位數	P5	P95	虧損機率	MDD 至少 20% 機率
單月 IID	13.70%	12.79%	-7.90%	38.27%	16.04%	3.02%
三個月區塊	13.15%	12.64%	-5.32%	33.54%	13.68%	0.66%



兩種拔靴法一年累積報酬分布

報酬表使用**一年累積報酬**，不是 CAGR；各抽樣路徑交易日數不同，原報告的 CAGR 中位數約 12.98% / 12.86%，與此表略異。單月法的 P5 ~ P95 是約 -8.13% ~ 37.81%，三個月區塊法約 -5.44% ~ 33.19%。

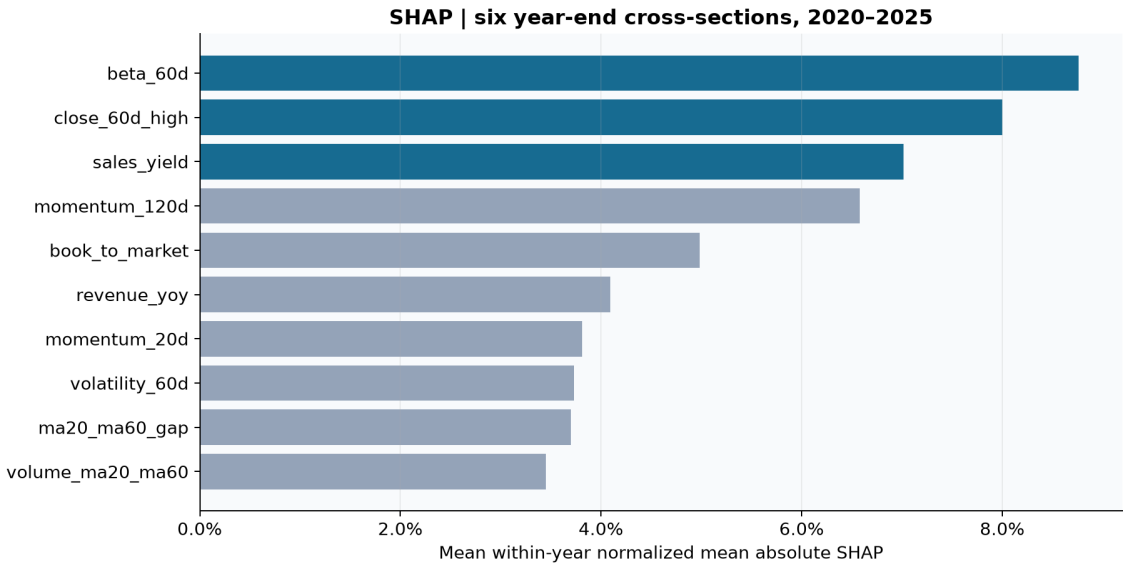
解讀界線：這是「歷史月份若能重複出現」的情境分布，不是未來預測保證，也不是平均績效的信賴區間。三個月區塊保留部分時間相依性，並不保證尾部風險估得更保守。模擬重用已扣成本的報酬，接縫不重建持股、不追加換倉成本；無法涵蓋歷史未見危機或消除選模偏誤。

來源：pseudohuber_bootstrap_summary_2020_2025.csv、pseudohuber_bootstrap_months_2020_2025.csv；既有互動式分布圖。

第八頁｜SHAP、限制與後續研究

特徵解釋的證據範圍

年度最後訊號	Top1	Top2	Top3
2020	beta_60d	momentum_120d	volatility_60d
2021	book_to_market	sales_yield	momentum_120d
2022	close_60d_high	beta_60d	volatility_60d
2023	beta_60d	close_60d_high	momentum_120d
2024	close_60d_high	beta_60d	momentum_20d
2025	sales_yield	close_60d_high	beta_60d



六個年度末截面的正規化 SHAP 平均重要度

首頁 Top3 採各年重要度總和正規化、再六年等權平均，以免單一年度預測尺度較大支配結果。最新 2025 年末截面 Top3 是 sales_yield、close_60d_high、beta_60d，與跨年摘要不同。beta_60d 表示市場敏感度；close_60d_high 表示股價相對 60 日高點的位置；sales_yield 為營收相對市值的估值因子；精確定義以程式為準。

SHAP 使用凍結模型對最後訊號月截面計算 mean(|SHAP|)，未提供方向性 beeswarm 或全年度分布，不能由絕對重要度推論「因子越高越應買」。相關因子也可能分攤重要度。來源：model_explain.shap_top；shap_snapshots.csv。

額外成果：2026 部分年度追蹤

既有 2026 YTD 報告估值至 **2026-10-16**：策略同期間累積報酬 23.65%、TAIEX 48.97%，MDD -8.17% / -16.36%；已成熟 1-8 月訊號平均 Rank IC 0.0282。這是首個執行日 NAV 起算口徑，**不與首頁混接**。9 月訊號的 20 日選股結果尚未成熟，應保持 N/A。此處只是已保存的追蹤快照，不代表截至本文件日期的最新行情。

來源：factor_v4_oos2026ytd_report.md。

面試呈現重點

- **量化分析師**：能解釋標籤、樣本外驗證、成本與曝險如何影響績效，並以消融 / 穩健性檢驗區分統計訊號與經濟價值。
- **機器學習工程師**：能串接資料擷取、特徵版本、凍結模型、run 級輸出與儀表板，且能辨識缺價、語意錯誤與指標口徑問題。
- **可守住的結論**：目前證據支持 Pseudo-Huber 作為後續研究基準；尚不足以宣稱可穩定打敗市場或直接實盤部署。

附錄｜圖表與來源管理

所有新圖均另存 PNG（簡報 / PDF）及 SVG（向量編輯），位於 output/research/research_results_assets/；圖中文字用英文短標籤，正文提供中文解釋。資料庫讀取為唯讀，未訓練模型或改動既有研究檔案。

檔案	用途
01_nav_drawdown	首頁延伸圖：淨值與回撤
02_methods	模型方法比較，2020-2024 年度平均
03_smoothing	α 與報酬 / 換手的取捨
04_bootstrap	兩種方法的一年累積報酬分布
05_shap	六個年度末截面 Top10 重要度摘要
stitched_daily.csv / annual_recomputed.csv	首頁與年度績效可重算底稿
methods_annual.csv / smoothing_annual.csv	方法與平滑的逐年明細與 run ID
shap_snapshots.csv / shap_summary.csv	SHAP 的原值與正規化摘要
provenance.json	本次使用 artifact 的 SHA-256；後續來源異動可偵測

重建文字與底稿：.venv/Scripts/python.exe output/research/build_research_results.py。作圖程式：output/research/plot_research_results.py（需要 matplotlib、pandas）。既有研究 CSV 與新資料庫快照分開標示；不把不同版本或不同期間的數字拼成單一排名。